

CONTROL DE CALIDAD DE DATOS & ARQUITECTURA CLOUD

REPORTE EJECUTIVO DE MONITOREO AMBIENTAL E INGESTA EN TIEMPO REAL

FRECUENCIA:
1 Minuto

ESTACIONES:
4 Sensores

ESTRATEGIA:
Híbrida C1 / C2

PLATAFORMA CLOUD:
AWS Serverless

E5. RESUMEN EJECUTIVO Y COBERTURA DE DATOS

El dataset analiza 4 estaciones de monitoreo continuo a 1 minuto (Pluviométrica 35, Meteorológica 367, Nivel 803 y Piranómetro 6004). El objetivo primordial es transicionar de una validación pasiva basada en etiquetas preexistentes hacia un **pipeline híbrido y multi-capa en tiempo real**, capaz de diferenciar eventos meteorológicos extremos de fallas operativas o desconfiguraciones físicas.

Estación	Cobertura / Gaps	Calidad Dif. a 1	Principal Riesgo / Hallazgo Operativo
Pluviométrica 35	~98.2% (1.8% gap)	8.4% de los datos	Descalibración de escala p1 frente a estación vecina
Meteorológica 367	~99.1% (0.9% gap)	3.1% de los datos	Humedad congelada al 100% durante eventos prolongados
Nivel 803	~97.5% (2.5% gap)	12.6% de los datos	Desplazamiento sistemático de cota cero (Nivel negativo)
Piranómetro 6004	~99.4% (0.6% gap)	14.2% de los datos	Desfase horario (+5h vs UTC) en estampa de tiempo

HALLAZGOS CRITICOS PRIORIZADOS

CRÍTICO 1. Desfase de Zona Horaria (Estación Piranómetro 6004)

La correlación solar máxima ocurre al aplicar un offset de **+5 horas**. Sin este ajuste, las reglas de radiación extraterrestre marcan falsos positivos en el 100% de los intervalos de amanecer y atardecer, corrompiendo el cálculo del índice de claridad.

ALTO 2. Desplazamiento de Cota Cero (Estación de Nivel 803)

Registro continuo de valores de nivel bajo cero (>1% de los datos) sin presencia de eventos de lluvia antecedente, lo que representa lecturas físicamente imposibles para cuerpos de agua superficiales.

MEDIO 3. Discrepancia de Escala de Lluvia (Estación 35 vs 367)

Las curvas de lluvia acumulada muestran una alta correlación lineal ($r > 0.95$), pero con una pendiente distorsionada (≈ 1.8), indicando una resolución de tip-bucket distinta o falta de calibración física.

MATRIZ COMPARATIVA DE ENFOQUES DE DETECCIÓN

Criterio	C1: Reglas Deterministas	C2: Métodos Estadísticos / ML	C3: Esquema Híbrido Propuesto
Latencia	< 10 ms (In-line)	~ 50-200 ms	Híbrido (Stream / Micro-batch)
Complejidad	Baja	Media - Alta	Balanceada
Falsos Positivos	Mínimos	Moderados (Eventos extremos)	Mínimos (Contextualizados)
Explicabilidad	100% Determinista	Caja Negra (Isolation Forest)	Total (Sistema de Banderas)
Cobertura	Fallas Conocidas	Patrones Complejos / Anomalías	Integral (Físico + EstAD)

RECOMENDACIONES ACCIONABLES DE CONTROL DE CALIDAD

Para garantizar la confiabilidad operacional de la red de sensores, se deben implementar inmediatamente tres acciones correctivas en el pipeline de datos:

1. **Normalización Temporal en Ingesta:** Ajustar automáticamente el desfase horario detectado (+5h) en el piranómetro 6004 a UTC antes de evaluar los modelos de radiación solar extraterrestre.
2. **Sistema de Banderas de Calidad Multi-bit:** Retener los datos originales y adjuntar vectores de calidad (OK, F, X, R, J, P, A, N, T, E) garantizando trazabilidad sin pérdida de información.
3. **Calibración Física de Campo:** Programar mantenimiento para la estación 803 (reinicio de cota cero) y ajuste del factor de escala del balancín en la estación pluviométrica 35.

PROPUESTA DE ARQUITECTURA CLOUD DE INGESTA Y VALIDACIÓN (AWS)

Diseño de pipeline ****Serverless, desacoplado y en tiempo real (sub-segundo)**** para procesar las lecturas de los sensores, ejecutar la validación C1/C2 y direccionar los datos hacia capas de almacenamiento optimizadas.



COMPONENTES CLAVE DE LA ARQUITECTURA CLOUD

1. Ingesta y Buffer Desacoplado:

AWS IoT Core gestiona la autenticación segura por certificados X.509. Amazon Kinesis Data Streams actúa como buffer distribuido tolerante a fallas.

2. Validación C1 Sub-Segundo:

AWS Lambda evalúa en milisegundos los límites físicos, tasas de cambio y persistencia. Aplica la corrección horaria solar para la estación 6004.

3. Validación ML C2 en Batch:

AWS Glue / SageMaker ejecuta algoritmos de Isolation Forest y MAD sobre ventanas móviles de tiempo para detectar derroteros atípicos multivariados.

4. Storage Multinivel & Alertas:

Timestream alimentará dashboards de tiempo real; Amazon S3 almacena el histórico en Parquet para Athena y SNS canaliza notificaciones urgentes.